

Algoritmos de clustering

Cómo las máquinas descubren el orden oculto en el caos a través del aprendizaje no supervisado.

El Primer Clúster: Londres, 1854

El Contexto Histórico

- **El Caos:** El cólera masacra la ciudad. La teoría oficial culpa a las miasmas (aire fétido).
- **El Pionero:** El médico John Snow marca cada muerte con un punto en un mapa.

La Revelación

- **El Patrón:** Aparece una aglomeración letal alrededor de un único elemento físico.
- **El Hito:** Sin ordenadores, Snow ejecutó a mano la esencia del agrupamiento: encontrar un orden perfecto en un mar de ruido.



Encontrar la verdad oculta sin tener las respuestas por adelantado.
Esta es la misión del Machine Learning no supervisado.


El Problema: Ordenar a Ciegas

El Cerebro Humano



Viene preprogramado biológicamente.
Separa las formas y colores casi sin
pensar usando intuición visual.

El Algoritmo (Ciego)



Solo procesa matrices de números
sin un manual de instrucciones.


La Pregunta Central: Si la máquina no sabe qué es un objeto, ¿cómo sabe qué piezas se parecen entre sí para poder juntarlas?

El Motor de Proximidad: Distancia Euclidiana

La Geometría de la Identidad

El algoritmo no ve el color rojo ni la forma cuadrada. Solo ve puntos en un espacio matemático de N-dimensiones.

Dime a qué distancia matemática estás de otro punto, y te diré si perteneces a su misma tribu.




El Teorema de Pitágoras Hiperdimensional

La regla fundamental del agrupamiento es implacable:
La proximidad física equivale a la identidad del grupo.

K-Means: El Burócrata con un Compás

El estándar de la industria opera a través de un bucle constante: el Baile de Dos Pasos.



Paso 0: La Caída Aleatoria (K)

Se elige cuántos grupos queremos (K). El algoritmo lanza centroides al azar sobre el mapa.

Paso 1: Asignación de Lealtades

Cada punto de datos jura lealtad incondicional al centroide más cercano. Se trazan fronteras rígidas (Diagramas de Voronoi).


Paso 2: Teletransporte a la Media

Los centroides calculan la ubicación media de todos sus súbditos y se mueven a esa nueva coordenada.

El bucle se repite a una velocidad asombrosa hasta que las fronteras se estabilizan.

La Fragilidad de K-Means

El Centroide Solitario



Fallo de Inicialización: Si los datos iniciales caen mal, un centroide puede quedar bloqueado en un desierto intentando dividir por cero.


El Problema del Smiley Face




La Dictadura del Compás: K-Means asume que el universo está hecho de esferas perfectas. Es ciego ante formas orgánicas, anillos o curvas.

El Cambio de Paradigma: DBSCAN

Abandonar los centros de gravedad para abrazar la topografía de la densidad.



El Enfoque Antiguo (Geometría)



Un ayuntamiento trazando líneas rectas en un mapa con un compás, ignorando si hay una montaña en medio del pueblo.

El Nuevo Enfoque (DBSCAN)



Un rumor propagándose en la pista de un festival de música abarrotado.

La Analogía del Rumor: El rumor salta de persona a persona de forma orgánica, amoldándose a la forma de la masa. Se detiene en seco al llegar a un espacio vacío donde no hay nadie.

La Anatomía de un Rumor (Mecánica DBSCAN)

El algoritmo clasifica el universo usando dos reglas: Epsilon (radio del brazo) y MinPoints (tamaño de la multitud).



Muestras Centrales (VIPs): El corazón palpitante. Logran atrapar dentro de su radar el mínimo de puntos exigidos. Propagan el rumor.




Puntos Fronterizos: No tienen suficientes amigos para ser VIPs, pero caen dentro del radio de un punto central. Son asimilados por la masa principal.



Ruido (Ermitaños): Valores atípicos perdidos en medio de la nada. DBSCAN no los fuerza a encajar; simplemente los ignora olímpicamente.

La Trampa del Mundo Real: Densidad Variable

El mundo real no tiene densidades constantes. Si DBSCAN opera con un radio (Epsilon) rígido e inamovible, se enfrenta a un callejón sin salida.



Si usamos un radio pequeño: Atrapa la galaxia densa perfectamente, pero clasifica el cúmulo disperso entero como ruido.



Si agrandamos el radio: Salva el cúmulo disperso, pero fusiona todas las galaxias densas vecinas en una sola masa amorfa gigante.

El talón de Aquiles: Un brazo de longitud fija no sirve en un universo de proporciones variables.

HDBSCAN y OPTICS: Topografía de Densidad

Eliminando la dictadura del parámetro fijo mediante gráficos de alcance (Reachability).

Valles Profundos: Datos muy apretados (distancias mínimas). Representan clústeres hiperdensos.

Montañas Altas: Espacios vacíos entre los datos. Representan las fronteras naturales.

Matrioskas de Datos: La estructura jerárquica permite identificar pequeños clústeres compactos anidados dentro de nubes más grandes y dispersas.

El algoritmo ya no busca con un radio rígido; asume todas las distancias posibles al mismo tiempo, extrayendo grupos de densidades radicalmente distintas.

La Matriz de Agrupamiento

	K-Means 	DBSCAN 	HDBSCAN 
Filosofía	Buscar centros de gravedad.	Propagar un rumor por contigüidad.	Mapeo topográfico jerárquico.
Geometría	Esferas perfectas, fronteras rectas.	Formas fluidas, anillos, curvas complejas.	Matrioskas de cualquier forma y densidad.
Ruido	Lo fuerza a entrar en un grupo; distorsiona todo.	Lo detecta y lo ignora de forma elegante.	Aislamiento de ruido altamente sofisticado.
Fallo	Ciego ante formas orgánicas; requiere inicio perfecto.	Falla estrepitosamente si la densidad varía.	Complejidad computacional superior.

La Paradoja de la Evaluación

El Muro de Hormigón del Aprendizaje No Supervisado

El ordenador trabaja completamente a oscuras. No tiene la plantilla con las respuestas correctas para saber si ha acertado. ¿Cómo le ponemos nota a un examen sin soluciones?

El Juez Sesgado (Coeficiente de Silueta)


La métrica más común para evaluar sin respuestas mide la cohesión interna frente a la separación externa.

- **La Trampa:** Está construida sobre distancias en línea recta. Es un juez al que solo le gustan los círculos perfectos.
- **El Resultado:** Penaliza brutalmente un anillo perfecto encontrado por DBSCAN solo porque sus extremos están muy separados.



El Método del Codo


Gráfico de Inercia



Pues mide qué tan apretados están los grupos... simples recortes arbitrarios.

The Elbow Method

Inertia Graph



It measures how tight the clusters are... merely arbitrary segments.

Midiendo el Éxito: Verdad Fundamental vs. Intrínseca



Verdad Fundamental (Ground Truth)

- **Cuándo:** En laboratorios perfectos donde sí conocemos las etiquetas previamente.
- **La Métrica:** **Índice de Rand Ajustado (ARI).**
- **El Mecanismo:** Coge los aciertos del modelo y le resta la probabilidad matemática de haber acertado por pura chiripa.
- **El Veredicto:** Elimina la suerte tirando los dados. Un juez implacable.



Evaluación Intrínseca

- **Cuándo:** En el mundo salvaje. Evaluar a ciegas la calidad geométrica del agrupamiento.
- **La Métrica:** **Coeficiente de Silueta.**
- **El Mecanismo:** Puntúa de -1 a 1 preguntando: ¿Estás pegado a los tuyos y lejos de tus vecinos?
- **El Veredicto:** Cuidado con el sesgo. No puede valorar geometrías complejas.

Síntesis Filosófica: Nombrando lo Innombrable

"El *clustering* no te da respuestas finales automáticas; te da pistas inteligentes para investigar."

Los algoritmos calculan distancias y alcanzan valles de densidad en espacios de 1,000 dimensiones con una frialdad pasmosa. No entienden de moral, ni de historia, ni de lenguaje. Solo buscan el orden subyacente.

¿Qué pasa cuando la matemática supera al lenguaje?

Si un algoritmo, analizando el océano de comportamientos sociales en internet, encuentra un clúster innegable que representa una nueva realidad humana... significa que los datos pueden ir por delante de la sociología.

Las máquinas podrían estar descubriendo las nuevas verdades de nuestra existencia mucho antes de que nosotros inventemos las palabras para nombrarlas. A veces, para entender a la humanidad, debemos dejar que las matemáticas hablen en la oscuridad.

